

基于多智能体深度强化学习的多无人机辅助移动边缘计算轨迹设计

徐少毅, 杨磊

(北京交通大学 电子信息工程学院, 北京 100044)

摘要: 无人机(Unmanned Aerial Vehicle, UAV)辅助的移动边缘计算(Mobile Edge Computing, MEC)网络能够为地面用户设备(User Equipment, UE)提供优质的计算服务,但是为多无人机进行实时的轨迹设计仍是一个挑战. 针对该问题,提出基于多智能体深度强化学习的轨迹设计算法,利用多智能体深度确定性策略梯度(Multi-Agent Deep Deterministic Policy Gradient, MADDPG)框架对无人机的轨迹进行协作设计. 考虑到无人机有限的电池容量是限制无人机网络性能的重要因素,因此以无人机的能量效率之和为优化目标构建优化问题,联合优化无人机集群的轨迹和用户设备的卸载决策. 每个智能体与边缘计算网络环境进行交互并观测自己的局部状态,通过Actor网络得到轨迹坐标,联合其他智能体的动作和观测训练Critic网络,从而改善Actor网络输出的轨迹策略. 仿真结果表明:基于MADDPG的无人机轨迹设计算法具有良好的收敛性和鲁棒性,能够高效地提升无人机的能量效率;所提算法性能较随机飞行算法最高可提升120%,较圆周飞行算法最高可提升20%,较深度确定性策略梯度算法可提升5%~10%.

关键词: 无人机轨迹设计;移动边缘计算;强化学习;多智能体深度确定性策略梯度

中图分类号: TN928

文献标志码: A

Trajectory design for multi-UAV-assisted mobile edge computing based on multi-agent deep reinforcement learning

XU Shaoyi, YANG Lei

(School of Electronic and Information Engineering, Beijing Jiaotong University, Beijing 100044, China)

Abstract: Unmanned Aerial Vehicle (UAV)-assisted Mobile Edge Computing (MEC) networks can provide high-quality computational services to ground User Equipment (UE), but real-time trajectory design for multiple UAVs remains a significant challenge. To address this issue, a trajectory design algorithm based on multi-agent deep reinforcement learning is proposed, utilizing the Multi-Agent Deep Deterministic Policy Gradient (MADDPG) framework to collaboratively design UAV trajectories. Considering the limited battery capacity of UAVs, a critical constraint on UAV network performance, the optimization problem is formulated to improve the sum of UAV energy efficiencies. This involves jointly optimizing the trajectories of UAV clusters and the offloading decisions of UEs. Each agent in-

收稿日期:2023-07-03;修回日期:2023-12-15

基金项目:国家重点研发计划(2022YFB3303702);国家自然科学基金(61931001)

Foundation items: National Key R&D Plan(2022YFB3303702); National Natural Science Foundation of China(61931001)

第一作者:徐少毅(1975—),女,河北廊坊人,教授,博士,博士生导师.研究方向为无线资源管理. **email:** shyxu@bjtu.edu.cn.

引用格式: 徐少毅,杨磊.基于多智能体深度强化学习的多无人机辅助移动边缘计算轨迹设计[J].北京交通大学学报,2024,48(5):1-9.
XU Shaoyi, YANG Lei. Trajectory design for multi-UAV-assisted mobile edge computing based on multi-agent deep reinforcement learning[J]. Journal of Beijing Jiaotong University, 2024, 48(5): 1-9. (in Chinese)

teracts with the edge computing network environment, observes its local state, and determines trajectory coordinates via an Actor network. The Critic network is trained by incorporating the action and observation of other agents, thereby refining the trajectory policy generated by the Actor network. Simulation results demonstrate that the MADDPG-based trajectory design algorithm exhibits excellent convergence and robustness, significantly enhancing UAV energy efficiency. Specifically, the proposed algorithm outperforms the random flight algorithm by 120% at most, the circular flight algorithm by 20% at most, and the Deep Deterministic Policy Gradient (DDPG) algorithm by 5% to 10%.

Keywords: UAV trajectory design; Mobile Edge Computing (MEC); reinforcement learning; Multi-Agent Deep Deterministic Policy Gradient (MADDPG)

移动边缘计算 (Mobile Edge Computing, MEC) 是一种可在网络边缘侧实现类似于云计算服务的网络架构, 通过在地面基站中部署相当于“微云”的边缘服务器, 周边的终端可以将本地处理较为困难的数据委托给计算能力更强的边缘服务器进行处理, 委托的过程也被称为任务卸载^[1]. 无人机 (Unmanned Aerial Vehicle, UAV) 又称无人驾驶飞机, 与地面通信系统 (如地面基站) 和高空平台相比, 部署成本更低, 并且具有按需操作、完全可控、能够快速和灵活部署等特点. 在灾区、临时热点区域等复杂的通信场景中, 基站无法实现用户的计算服务, 为满足用户的计算需求并解决多设备接入时会出现的链路阻塞问题, 现有研究将边缘服务器部署在无人机上组成无人机辅助的 MEC 网络以满足通信要求.

在无人机辅助的 MEC 网络中, 资源受限的移动设备能够将其计算密集型任务卸载到具有强计算能力的无人机上. 这种利用无人机的灵活性与较高的信道增益为用户计算卸载任务的方式, 不但能节省计算时延与用户能源, 也可以减少固定云服务器上的流量负载.

尽管无人机辅助 MEC 网络前景广阔, 但同时也存在不少问题亟待解决. 目前大多数研究都只专注于单无人机的二维或三维位置部署^[2-4]. 虽然单架无人机可以提高网络性能, 但其通信、缓存和计算能力有限, 难以为复杂地区中的大量用户提供服务, 而部署多架无人机可以解决该问题^[5]. 在多无人机通信系统中, 多架无人机可以在大范围内协同为地面用户服务^[6], 具有更低的延迟和更高的吞吐量.

虽然多无人机辅助的 MEC 网络覆盖范围更广, 但需要额外考虑协作轨迹设计问题. 目前, 已有学者进行了相关研究. 文献[7-8]将原始的非凸问题分解为多个子问题, 并采用连续凸近似 (Successive Convex Approximation, SCA) 等数学方法将非凸的无人机轨迹设计子问题转化为凸问题进行求解. 文献[9]牺牲无人机的飞行优势, 提出一种带有消除算

子的差分进化算法来优化无人机的静态部署位置. 算法以精确性为代价, 得到的是原问题的次优解. 随着无人机数量的增加, 算法的计算复杂度呈指数级增长, 并且当环境发生变化时, 还需重新计算优化过程, 难以在动态场景中部署和实现.

为了适用动态场景, 深度强化学习 (Deep Reinforcement Learning, DRL) 被逐渐应用于无人机辅助通信网络, 它可以解决被建模为马尔可夫决策过程 (Markov Decision Process, MDP) 的问题. 文献[10]考虑无人机的能效和避障问题, 每架无人机从预设的起点到目的地执行任务, 通过获取环境信息进行实时避障, 基于改进的孪生延迟深度确定性策略梯度算法对无人机的轨迹进行优化, 但所提算法并未考虑无人机之间的合作. 文献[11]基于多智能体深度确定性策略梯度 (Multi-Agent Deep Deterministic Policy Gradient, MADDPG) 算法对无人机的轨迹进行设计, 考虑了无人机负载均衡和能耗的公平性, 但忽略了无人机的最大可用能耗约束. 文献[12]通过联合优化无人机的轨迹、任务分配和无线资源, 最小化任务的计算延迟和无人机的能耗, 并提出基于 TD3 的高效求解算法.

综上, 针对无人机的机载能量有限的问题, 本文以最大化无人机的能量效率之和为优化目标, 利用多智能体强化学习算法实现多无人机辅助 MEC 网络中的无人机轨迹设计. 首先, 分析网络模型, 建立无人机轨迹和用户卸载决策的联合优化问题; 然后, 设计基于深度强化学习的集中式训练算法, 将每架无人机视作一个智能体, 定义状态、动作以及奖励函数; 最后, 每个智能体通过与环境交互进行学习, 得到最优的轨迹策略.

1 系统模型与问题建模

1.1 网络架构

多无人机辅助的移动边缘计算网络如图 1 所示, 网络中包括 J 个无人机和 I 个地面用户设备

(User Equipment, UE), J 个无人机为地面 I 个用户设备提供计算服务. 无人机集合和地面用户设备集合分别用 $\mathcal{J}=\{1, 2, \dots, J\}$ 和 $\mathcal{I}=\{1, 2, \dots, I\}$ 表示. 用户设备随机分布在边长为 $l_{\max}$ 的方形区域中, 无人机飞行在固定的高度为用户提供计算服务.




图1 多无人机辅助的MEC网络

Fig.1 Multi-UAV-assisted MEC network

无人机的服务周期可以划分成 T 个相等的时隙, 即 $\mathcal{T}=\{1, 2, \dots, T\}$, 每个时隙的长度为 τ . 假设每个用户设备在每个时隙 t 都有一个计算任务需要处理, 任务可以在本地处理也可以卸载到无人机上处理. 第 i 个用户设备在第 t 个时隙的计算任务可以表示为^[11]

$$U_i(t) = (D_i(t), C_i(t)) \quad (1)$$

式中: $D_i(t)$ 表示任务的数据大小; $C_i(t)$ 表示该任务所需的CPU周期.

定义卸载决策变量为

$$\eta_{ij}(t) = \{0, 1\} \quad (2)$$

$\eta_{ij}(t) = 1$ 表示在时隙 t 的时候, 用户 i 将任务 $U_i(t)$ 卸载到无人机 j 上处理, 否则表示卸载到其他无人机或在本地处理. 由于计算任务只能本地处理或卸载到一个无人机上, 因此可以得到约束

$$\sum_{j=1}^J \eta_{ij}(t) \leq 1 \quad (3)$$

1.2 通信模型

地面用户设备 i 的坐标可以表示为 $q_i = (x_i, y_i, 0)$, 无人机 j 在时隙 t 的坐标可以表示为 $q_j(t) = (x_j(t), y_j(t), H)$, H 为无人机飞行的固定高度. 为给用户提供 MEC 服务, 无人机不能飞出边界, 即

$$0 \leq x_j(t) \leq l_{\max} \quad (4)$$

$$0 \leq y_j(t) \leq l_{\max} \quad (5)$$

无人机 j 和用户 i 在时隙 t 的水平距离为

$$R_{ij}(t) = \sqrt{(x_j(t) - x_i)^2 + (y_j(t) - y_i)^2} \quad (6)$$

如果用户 i 决定在时隙 t 将任务卸载到无人机 j 上处理, 则它必须在无人机的覆盖范围内, 即

$$\eta_{ij}(t) R_{ij}(t) \leq R_{\text{serve}} \quad (7)$$

式中, R_{serve} 表示用户可以卸载到无人机上的极限水平距离. 在时隙 t , 无人机 j 和 j' 间的水平距离为

$$R_{jj'}(t) = \sqrt{(x_j(t) - x_{j'}(t))^2 + (y_j(t) - y_{j'}(t))^2} \quad (8)$$

为避免无人机在飞行的时候发生碰撞, 无人机之间的飞行距离不能超过安全距离 R_{safe} , 即

$$R_{jj'}(t) \geq R_{\text{safe}} \quad (9)$$

考虑无人机和用户之间的通信链路包括直射路径 (Line-of-Sight, LoS) 和非直射路径 (Non-Line-of-Sight, NLoS), 因此路径损耗分别为^[13]

$$PL_{ij}^{\text{LoS}}(t) = L_{ij}^{\text{FS}}(t) + 20 \log(R_{ij}(t)) + \eta_{\text{LoS}} \quad (10)$$

$$PL_{ij}^{\text{NLoS}}(t) = L_{ij}^{\text{FS}}(t) + 20 \log(R_{ij}(t)) + \eta_{\text{NLoS}} \quad (11)$$

式中: $L_{ij}^{\text{FS}}(t)$ 为自由空间路径损耗, $L_{ij}^{\text{FS}}(t) = 20 \log(f) + 20 \log(4\pi/c)$, f 为系统载频, c 为光速; η_{LoS} 和 η_{NLoS} 分别为 LoS 和 NLoS 连接引起的附加衰减因子. 无人机 j 和用户 i 之间 LoS 连接的概率为

$$P_{ij}^{\text{LoS}}(t) = \frac{1}{1 + b_1 \exp(-b_2(\theta_{ij}(t) - b_1))} \quad (12)$$

式中: b_1 和 b_2 是依赖于环境的常数; $\theta_{ij}(t)$ 为高度角, $\theta_{ij}(t) = \sin^{-1}(H/R_{ij}(t))$. 无人机 j 和用户 i 之间平均路径损耗可表示为

$$PL_{ij}(t) = P_{ij}^{\text{LoS}}(t) \times PL_{ij}^{\text{LoS}}(t) + (1 - P_{ij}^{\text{LoS}}(t)) \times PL_{ij}^{\text{NLoS}}(t) \quad (13)$$

式中: $PL_{ij}^{\text{LoS}}(t)$ 和 $PL_{ij}^{\text{NLoS}}(t)$ 分别为 LoS 和 NLoS 连接产生的路径损耗.

若用户 i 的卸载功率为 $P_i(t)$, 则在无人机侧的接收功率 $P_{ij}(t)$ 可以表示为

$$P_{ij}(t) = \frac{P_i(t)}{10^{PL_{ij}(t)/10}} \quad (14)$$

因此, 用户 i 的卸载速率 $r_{ij}(t)$ 为

$$r_{ij}(t) = w \log \left(1 + \frac{P_{ij}(t)}{\sigma^2 + \sum_{i'=1, i' \neq i}^I P_{i'j}(t)} \right) \quad (15)$$

式中: w 是用户占用的通信带宽; σ^2 是噪声功率; $P_{i'j}(t)$ 是来自其他用户的干扰.

1.3 时延模型

如果用户 i 选择在本地处理任务, 那么相应的计算时延可以表示为

$$T_i^l(t) = \frac{C_i(t)}{f_i^l} \quad (16)$$

式中, f_i^l 表示用户 i 的计算频率.

如果用户 i 选择将任务卸载到无人机 j 上, 不考虑处理结果的返回过程, 任务处理的时延仅由卸载

传输时延和计算时延组成^[14],即

$$T_{ij}^e(t) = \frac{D_i(t)}{r_{ij}(t)} + \frac{C_i(t)}{f_{ij}(t)} \quad (17)$$

式中, $f_{ij}(t)$ 表示无人机 j 的计算频率.

用户会选择时延更小的方式处理计算任务, 如果卸载任务的处理时延不超过本地处理任务的时延, 任务就会被卸载到无人机上, 即

$$T_{ij}^e(t) \leq T_i^l(t) \quad (18)$$

因此, 当任务被卸载到无人机上时, $f_{ij}(t)$ 需要满足

$$f_{ij}(t) \geq \frac{f_i^l C_i(t)}{C_i(t) - D_i(t) f_i^l / r_{ij}(t)} \quad (19)$$

同时, 考虑到任务 $U_i(t)$ 应该在时隙 t 内处理完毕, 可以得到

$$\eta_{ij}(t) T_{ij}^e(t) + [1 - \eta_{ij}(t)] T_i^l(t) \leq \tau \quad (20)$$

由式(20)可知, f_i^l 和 $f_{ij}(t)$ 需要满足

$$f_i^l \geq \frac{C_i(t)}{\tau} \quad (21)$$

$$f_{ij}(t) \geq \frac{C_i(t) r_{ij}(t)}{\tau r_{ij}(t) - D_i(t)} \quad (22)$$

根据分析, 如果用户 i 在时隙 t 选择将任务卸载到无人机节点 j 上, 无人机 j 需要分配给任务 $U_i(t)$ 的计算资源应该满足

$$f_{ij}(t) \geq \max \left\{ \frac{f_i^l C_i(t)}{C_i(t) - D_i(t) f_i^l / r_{ij}(t)}, \frac{C_i(t) r_{ij}(t)}{\tau r_{ij}(t) - D_i(t)} \right\} = \hat{f}_{ij}(t) \quad (23)$$

式中, $\hat{f}_{ij}(t)$ 为无人机 j 需要分配的最少的计算资源. 假设无人机拥有足够多的计算资源, 为减轻地面设备的计算负担, 任务更应该被卸载到无人机上处理.

1.4 能耗模型

无人机 j 在时隙 t 的飞行功耗可以表示为^[15]

$$P_j^f(t) = \begin{cases} P_0 & \|v_j(t)\| = 0 \\ \omega_1 \|v_j(t)\|^3 + \frac{\omega_2}{\|v_j(t)\|} \left(1 + \frac{\|u_j(t)\|^2}{g^2} \right) & \|v_j(t)\| \neq 0 \end{cases} \quad (24)$$

式中: P_0 是无人机的悬停功耗; ω_1 和 ω_2 都是固定参数; g 是重力加速度. $v_j(t)$ 和 $u_j(t)$ 分别是无人机 j 在时隙 t 的速度和加速度, 具体为

$$v_j(t) = \frac{q_j(t) - q_j(t-1)}{\tau} \quad (25)$$

$$u_j(t) = \frac{v_j(t) - v_j(t-1)}{\tau} \quad (26)$$

假设无人机的飞行速度不能超过最大速度 $V_{\max}$, 即

$$\|v_j(t)\| \leq V_{\max} \quad (27)$$

那么无人机 j 在时隙 t 的飞行能耗可以表示为

$$E_j^f(t) = P_j^f(t) \tau \quad (28)$$

无人机 j 在时隙 t 计算用户 i 的任务所产生的能耗为^[16]

$$E_{ij}(t) = \kappa_1 [f_{ij}(t)]^{\kappa_2} \frac{C_i(t)}{f_{ij}(t)} \quad (29)$$

式中: κ_1, κ_2 是相关的能耗系数, $\kappa_1 > 0, \kappa_2 > 1$. 考虑到无人机在一个服务周期内消耗的能量不能超过它储存的最大能量 $E_{\max}$, 因此存在约束

$$\sum_{t=1}^T \left(\sum_{i=1}^I \eta_{ij}(t) E_{ij}(t) + E_j^f(t) \right) \leq E_{\max} \quad (30)$$

无人机 j 在时隙 t 的能量效率定义为

$$e_j(t) = \frac{\sum_{i=1}^I \eta_{ij}(t) D_i(t)}{\sum_{i=1}^I \eta_{ij}(t) E_{ij}(t) + E_j^f(t)} \quad (31)$$

1.5 优化问题

无人机携带的电池容量有限, 而在复杂的灾区救援环境中, 无人机充电又极其困难, 因而能效问题对于无人机十分重要. 本文以最大化无人机集合的能量效率之和为优化目标, 希望无人机在能量有限的情况下, 尽可能处理更多的计算任务. 根据各约束条件, 建立优化问题, 目标函数为

$$O = \max_{Z, U} \sum_{t=1}^T \sum_{j=1}^J e_j(t) \quad (32)$$

$$\text{s.t.} \begin{cases} \eta_{ij}(t) \in \{0, 1\} \quad \forall i \in \mathcal{I}, j \in \mathcal{J}, t \in \mathcal{T} \\ \sum_{j=1}^J \eta_{ij}(t) \leq 1 \quad \forall i \in \mathcal{I}, j \in \mathcal{J}, t \in \mathcal{T} \\ 0 \leq x_j(t) \leq l_{\max} \quad \forall j \in \mathcal{J}, t \in \mathcal{T} \\ 0 \leq y_j(t) \leq l_{\max} \quad \forall j \in \mathcal{J}, t \in \mathcal{T} \\ \eta_{ij}(t) R_{ij}(t) \leq R_{\text{serve}} \quad \forall i \in \mathcal{I}, j \in \mathcal{J}, t \in \mathcal{T} \\ R_{jj'}(t) \geq R_{\text{safe}} \quad \forall j, j' \in \mathcal{J}, t \in \mathcal{T} \\ \eta_{ij}(t) T_{ij}^e(t) + [1 - \eta_{ij}(t)] T_i^l(t) \leq \tau \\ \forall i \in \mathcal{I}, j \in \mathcal{J}, t \in \mathcal{T} \\ \|v_j(t)\| \leq V_{\max} \quad \forall j \in \mathcal{J}, t \in \mathcal{T} \\ \sum_{t=1}^T \left(\sum_{i=1}^I \eta_{ij}(t) E_{ij}(t) + E_j^f(t) \right) \leq E_{\max} \\ \forall i \in \mathcal{I}, j \in \mathcal{J}, t \in \mathcal{T} \end{cases} \quad (33)$$

式中: Z 和 U 是待优化的矩阵, $Z = \{\eta_{ij}(t), \forall i \in \mathcal{I}, j \in \mathcal{J}, t \in \mathcal{T}\}$; $U = \{q_j(t), \forall j \in \mathcal{J}, t \in \mathcal{T}\}$.

由式(32)和(33)可知, 优化问题是混合整数的非凸优化问题, 传统的方法很难求解, 因此本文基于

多智能体深度强化学习算法提出多无人机协同的轨迹设计方法,以最大化无人机集合的能量效率之和。

2 基于MADDPG的无人机轨迹设计

2.1 随机博弈建模

利用多智能体强化学习算法前需要先将问题建模为马尔科夫博弈问题。马尔科夫博弈又称为随机博弈,一般用一个元组 (S, A, R, P, γ) 来定义。

1) S 是描述环境的状态集合;

2) $A = \{A_1, A_2, \dots, A_J\}$ 是所有智能体的联合动作集合;

3) $R = \{R_1, R_2, \dots, R_J\}$ 是将环境状态和智能体的动作映射为奖励的奖励函数集合,即 $R: S \times A \mapsto R_J$;

4) P 是描述概率的状态转移函数;

5) γ 是奖励折扣因子。

许多马尔科夫博弈是部分可观测的,因此智能体只能观测到部分环境状态^[17],将无人机视作智能体,定义每个智能体的观测、动作和奖励函数。

1) 观测 $o_j(t)$ 。智能体 j 的观测应该包含其本身的位置信息 $q_j(t)$ 。同时,智能体 j 也能够观测到其他智能体的位置信息 $\{q_{j'}(t), \forall j' \in \mathcal{J}, j' \neq j\}$ 以进行信息交互并避免发生碰撞。因此,智能体 j 在时隙 t 的观测为 $o_j(t) = \{q_j(t), \forall j \in \mathcal{J}\}$ 。

2) 动作 $a_j(t)$ 。定义智能体 j 在时隙 t 的动作为下一时隙 $t+1$ 的坐标,即 $a_j(t) = q_j(t+1)$ 。

3) 奖励函数 $r_j(t)$ 。定义智能体 j 在时隙 t 的奖励函数为

$$r_j(t) = e_j(t) - (\xi_j^b(t) \times r^b + \xi_j^d(t) \times r^d) \quad (34)$$

式中: r^b 为无人机 j 飞出目标区域的惩罚; r^d 为无人机 j 与其他无人机相撞时的惩罚;二元变量 $\xi_j^b(t)$ 和 $\xi_j^d(t)$ 用于指示无人机是否应该受到相应的惩罚。 $\xi_j^b(t) = 1$ 表示无人机 j 飞出目标区域,否则 $\xi_j^b(t) = 0$; $\xi_j^d(t) = 1$ 表示无人机 j 违反最小飞行距离约束,否则 $\xi_j^d(t) = 0$ 。

定义系统的联合观测 $o(t)$ 、联合动作 $a(t)$ 以及联合奖励函数 $r(t)$ 分别为所有智能体的观测、动作、奖励函数组成的集合。

2.2 MADDPG 算法

本文基于多智能体强化学习中的MADDPG框架进行无人机轨迹设计。MADDPG框架如图2所示,遵循集中训练、分散执行的原则。在训练过程中,智能体之间可以交换彼此的信息,每个智能体需要基于所有智能体的观测和动作进行训练;而在分




图2 MADDPG 框架

Fig.2 Framework of MADDPG

散执行阶段,每个智能体都可以基于自己局部的观测作出决策。所有智能体的目标都是找到一个策略以最大化自己的奖励函数。

此外,MADDPG算法采用Actor-Critic架构。每个智能体都有两种神经网络,一种是参数为 θ_j^π 的Actor网络 $\pi_j(o_j; \theta_j^\pi)$,另一种是参数为 θ_j^Q 的Critic网络 $Q_j(o; a; \theta_j^Q)$ 。Actor网络 $\pi_j(o_j; \theta_j^\pi)$ 输入智能体 j 的观测 o_j ,输出动作 a_j ;Critic网络通过访问所有智能体的观测和动作来评估Actor网络的输出。

MADDPG采用经验回放和目标网络技术以避免训练的发散^[18]。在每个时隙,智能体将相应的经验元组 $(o(t), a(t), r(t), o(t+1))$ 存储到大小为 B 的经验缓存池中。如果经验池已满,则新生成的经验元组将替换旧的经验元组。Actor和Critic网络的训练数据从经验池中批量采样。随机样本打破了序列样本间的相关性,减少训练振荡。智能体 j 的Critic网络通过最小化均方误差损失更新,计算式为

$$L(\theta_j^Q) = \frac{1}{N_b} \sum_{i=1}^T [z_j(t) - Q_j(o(t), a(t); \theta_j^Q)]^2 \quad (35)$$

式中: N_b 是随机抽样的样本数量; $z_j(t)$ 是更新目标,表示为

$$z_j(t) = r_j(t) + \gamma Q_j'(o(t+1), \{\pi_1'(o_1(t+1); \theta_1^{\pi'}), \pi_2'(o_2(t+1); \theta_2^{\pi'}), \dots, \pi_j'(o_j(t+1); \theta_j^{\pi'})\}; \theta_j^{Q'}) \quad (36)$$

式中: $Q_j'(o; a; \theta_j^{Q'})$ 是参数为 $\theta_j^{Q'}$ 的目标Critic网络; $\pi_j'(o_j; \theta_j^{\pi'})$ 是参数为 $\theta_j^{\pi'}$ 的目标Actor网络。

智能体 j 的Actor网络通过最小化损失函数更新,计算式为

$$L(\theta_j^\pi) = -\frac{1}{N_b} \sum_{i=1}^J Q_j(o(t), \{a_1(t), a_2(t), \dots, a_j(t), \dots, a_J(t); \theta_j^Q\}) \quad (37)$$

式中, $a_j(t)$ 是由 Critic 网络输出的动作, $a_j(t) = \pi_j(o_j(t); \theta_j^*)$.

目标网络参数 θ' 的更新计算式为^[19]

$$\theta' \leftarrow \epsilon \theta + (1 - \epsilon) \theta' \quad \epsilon \ll 1 \quad (38)$$

式中, ϵ 是目标网络的更新速率.

在基于 MADDPG 算法框架对无人机轨迹进行协同优化的同时, UE 的卸载决策需要得到确定. 假设无人机拥有足够多的计算资源, UE 进行卸载决策的计算式为

$$\eta_{ij}(t) = \begin{cases} 1 & R_{ij}(t) \leq R_{\text{serve}}, j = \arg \min_{j \in \mathcal{J}} \{R_{ij}(t)\} \\ 0 & \text{其他} \end{cases} \quad (39)$$

由式(39)可知, 无人机移动后, 每个用户设备选择距离最近的无人机进行卸载, 否则 UE 会在本地计算任务. 用户设备与无人机之间的距离越近, 则卸载速率越大、计算任务所需的计算资源就越少, 计算能耗越少, 无人机的能量效率越高. 如果用户 i 决定将任务卸载给无人机 j , 那么无人机分配给用户的计算资源为 $\hat{f}_{ij}(t)$.

2.3 基于 MADDPG 的多无人机轨迹优化算法

设计基于 MADDPG 的多无人机轨迹优化算法. 在智能体开始训练前, 对所有 Actor 网络、Critic 网络及相应的目标网络进行初始化. 本文以长度为 T 的 Episode 为训练单元开展训练, 算法包括 3 个步骤.

步骤 1: 在每个 Episode 开始时, 每个无人机在初始位置观测环境得到观测值 $o_j(t)$, 将观测值 $o_j(t)$ 输入 Actor 网络 $\pi_j(o_j; \theta_j^*)$ 后得到输出动作. 为防止学习到的策略陷入局部最优, 智能体实际选择动作的计算式为

$$a_j(t) = \pi_j(o_j(t); \theta_j^*) + N \quad (40)$$

式中, N 是训练过程的噪声参数, 服从均值为零、方差为 σ_N 的正态分布.

步骤 2: 无人机执行联合动作 $a(t)$, 环境状态从 $s(t)$ 转变成 $s(t+1)$. 智能体获得奖励函数 $r(t)$ 并在下一时隙继续观测环境得到 $o(t+1)$. 如果无人机飞出边界或进入其他无人机的安全飞行区域, 则对其进行惩罚. 经验元组 $(o(t), a(t), r(t), o(t+1))$ 存储在经验缓存池中.

步骤 3: 当经验池存满时, 对经验元组进行批量采样, 通过最小化相应的损失函数来更新所有智能体的 Actor 网络和 Critic 网络, 并通过缓慢跟踪学习到的网络来更新所有智能体的目标网络.

综上, 实现算法描述为

- 1: 初始化经验缓存池 B 、所有智能体的 Actor 和 Critic 网络及对应的目标网络参数
- 2: for each Episode do

- 3: 初始化无人机的位置
- 4: for each time slot t do
- 5: for UAV j in $\mathcal{J}$ do
- 6: 观察环境得到 $o_j(t)$
- 7: 根据式(40)选择动作 $a_j(t)$
- 8: end for
- 9: 得到 $a(t)$ 和 $o(t)$
- 10: for UE i in $\mathcal{I}$ do
- 11: 根据式(39)得到卸载决策
- 12: end for
- 13: 所有无人机采取动作 $a(t)$
- 14: for UAV j in $\mathcal{J}$ do
- 15: 根据式(34)得到奖励 $r_j(t)$
- 16: 观察环境得到 $o_j(t+1)$
- 17: end for
- 18: 得到 $r(t)$ 和 $o(t+1)$
- 19: 将元组 $(o(t), a(t), r(t), o(t+1))$ 存储在经验缓存池 B 中
- 20: end for
- 21: if B is full then
- 22: 从经验缓存池 B 中进行批量采样
- 23: for UAV j in $\mathcal{J}$ do
- 24: 更新 Critic 网络和 Actor 网络参数
- 25: 更新 Critic 和 Actor 目标网络参数
- 26: end for
- 27: end if
- 28: end for

3 实验仿真

3.1 仿真环境

为评估所提算法的性能, 在 TensorFlow 平台上使用 Python3.6 进行仿真分析. 所有的用户设备随机分布在边长为 $l_{\max} = 100$ m 的正方形区域, 无人机的飞行高度均为 50 m, 初始水平坐标分别设定为 $[10, 10]$ 、 $[90, 90]$ 、 $[10, 90]$ 和 $[90, 10]$. 无人机的飞行速度不能超过 $V_{\max} = 20$ m/s, 并且飞行间距不能超过 $R_{\text{safe}} = 3$ m, 以免发生碰撞. 每个用户在每个时隙中产生一个任务, 其拥有的通信带宽 $w = 10$ MHz, 发射功率 $P_{\max} = 0.1$ W. 所有智能体的 Actor 网络和 Critic 网络均采用 3 个全连接的隐藏层, 并且由修正线性单元 ReLU 激活. 仿真时使用学习率为 0.01 的适应性矩估计 (Adaptive Momentum Estimation, Adam) 优化器更新所有智能体的 Actor 网络和 Critic 网络. 其他参数取值见表 1.

3.2 基准算法

将提出的算法与 3 种基准算法进行比较.

- 1) 随机飞行算法 RANDOM. 每个无人机在目

表1 仿真参数

Tab.1 Simulation parameters

参数	取值	参数	取值
时隙数量 T	20	参考距离处的信道增益 β_0	1.42×10^{-4}
时隙长度 τ/s	1	目标网络更新速率 ϵ	0.01
计算任务大小 $D_i(t)/kb$	[10, 14]	折扣因子 γ	0.95
计算任务所需 CPU 周期 $C_i(t)/(cycles/bit)$	[1 800, 2 000]	无人机越界惩罚 r^b	100
用户 i 的本地计算能力 f_i^l/MHz	[0.20, 0.22]	无人机碰撞惩罚 r^d	100
无人机的水平覆盖半径 R_{serve}/m	20	经验元组抽样数量 N_b	1 024
无人机的悬停功耗 P_0/W	300	经验池大小 B	1.0×10^6
噪声功率 σ^2/dBm	-90	—	—

标区域内随机飞行,即在每个时隙随机选择飞行方向和飞行距离。

2) 圆周飞行算法 CIRCLE. 每个无人机围绕自己的圆心位置进行圆周飞行,圆周的半径为 R_{max} 。

3) 深度确定性策略梯度算法 DDPG. 同样将无人机视作具有 Actor 网络和 Critic 网络的智能体,基于智能体的本地观测和奖励函数进行训练。

3.3 仿真结果分析

图3是基于MADDPG算法的训练曲线。由图3可知:①在目标区域有2架无人机和20个用户设备的情况下,系统累积奖励初始不超过1 000,在10 000 Episode后逐渐增加,40 000 Episode后收敛到4 500。②当目标区域存在3架无人机和15个用户设备时,累积奖励在开始时为负值,36 000 Episode后收敛到3 200。③后者收敛的奖励值更低,这是因为该场景中用户设备数量更少、无人机数量更多,导致系统中计算任务减少、无人机碰撞的概率增加。





图3 基于MADDPG的训练曲线

Fig.3 Training curves based on the MADDPG


为更好地理解MADDPG算法的优势,绘制智能体在训练过程中系统能量效率的变化曲线,如图4所示。由图4可知:①目标区域存在2架无人机和20个用户设备时,智能体在学习迭代20 000次以后,基于MADDPG算法和DDPG算法所获得的能

量效率均开始收敛,且高于随机飞行算法和圆周飞行算法;②与DDPG算法相比,MADDPG算法可以收敛到更高的能量效率。这是因为在基于MADDPG算法训练时,智能体之间彼此协作,每个智能体都会根据全局的观测和动作训练Critic网络,因此系统可以获得更高的能量效率;而基于DDPG算法训练时,智能体独立学习,只基于本地的观测和动作训练Critic网络。

图5为无人机的轨迹曲线。由图5可知:①目标区域存在2架无人机和20个用户设备时,无人机1




(a) 目标区域存在2架无人机和20个用户




(b) 目标区域存在3架无人机和15个用户

图4 智能体训练过程中系统能量效率的变化曲线

Fig.4 Curves of system energy efficiency when agents are training



(a) 目标区域存在2架无人机和20个用户



(b) 目标区域存在3架无人机和15个用户

图5 无人机轨迹

Fig.5 UAVs' trajectories

从其初始位置移动到左上角,而无人机2向右上角飞行,从而可以服务目标区域中的所有用户设备;②每架无人机飞行在特定的区域,以服务更多的用户设备,且在飞行时进行分工协作以获得更多奖励。

图6为无人机和用户数量对系统性能的影响曲线。由图6可知:随着无人机和用户数量的增加,无人机的能量效率会逐渐上升。用户数量增加,则更多的计算任务可以卸载至无人机侧处理,因此系统能效增加;无人机数量增加,则能效的求和项增加,更多的用户可以得到无人机的计算服务,而由于无人机在一个时隙的耗能远小于计算任务的大小,因此能效总和增加。

图7对比了不同算法下无人机能效总和与用户数量的关系。由图7可知:①无人机的能量效率总和随用户数量的增加而增加。②基于MADDPG的无人机轨迹设计算法性能最优,较随机飞行算法最高




图6 无人机和用户数量对系统能量效率的影响

Fig.6 Impact of UAV and UE quantities on system energy efficiency




图7 优化算法和用户数量对系统能量效率的影响

Fig.7 Impact of optimization algorithms and UE quantity on system energy efficiency

提升了120%,较圆周飞行算法最高提升了20%,较DDPG算法的性能提升了5%~10%。不同算法的性能差异表明,无人机之间的适当协作可以更高效地为用户提供计算服务。

4 结论

1) 针对多无人机辅助的边缘计算网络,以最大化无人机的能量效率为优化目标,构建用户卸载决策和无人机轨迹的联合优化问题。考虑到该问题是混合整数的非凸问题,本文提出基于多智能体深度强化学习的多无人机轨迹设计算法。

2) 在无人机和用户设备数量不同的情况下,基于MADDPG算法进行训练,验证了所提算法的收敛性和鲁棒性。根据训练结果绘制的无人机轨迹显示,无人机之间进行分工合作能够获取更高的奖励。

3) 在用户数量不同的情况下,将所提MADDPG算法与DDPG、随机飞行和圆周飞行算法进行对比,仿真结果表明MADDPG的无人机轨迹设计算法性能最优,较随机飞行算法最高提升了

120%,较圆周飞行算法最高提升了20%,较DDPG算法提升了5%~10%。

目前考虑的场景模型过于理想,未来工作可以考虑进一步完善系统模型,如考虑在无人机计算资源受限、用户可移动的前提下对无人机的计算资源和用户的卸载决策进行联合优化。

参考文献(References):

- [1] BAKTIR A C, OZGOVDE A, ERSOY C. How can edge computing benefit from software-defined networking: A survey, use cases, and future directions[J]. *IEEE Communications Surveys & Tutorials*, 2017, 19(4): 2359—2391.
- [2] HU Q Y, CAI Y L, YU G D, et al. Joint offloading and trajectory design for UAV-enabled mobile edge computing systems[J]. *IEEE Internet of Things Journal*, 2019, 6(2): 1879—1892.
- [3] LIU Y, QIU M, HU J L, et al. Incentive UAV-enabled mobile edge computing based on microwave power transmission[J]. *IEEE Access*, 2020, 8: 28584—28593.
- [4] YU Z, GONG Y M, GONG S M, et al. Joint task offloading and resource allocation in UAV-enabled mobile edge computing[J]. *IEEE Internet of Things Journal*, 2020, 7(4): 3147—3159.
- [5] LUO J J, SONG J L, ZHENG F C, et al. User-centric UAV deployment and content placement in cache-enabled multi-UAV networks[J]. *IEEE Transactions on Vehicular Technology*, 2022, 71(5): 5656—5660.
- [6] LI Y B, ZHANG S T, CHEN J, et al. Multi-UAV cooperative mission assignment algorithm based on ACO method[C]//2020 International Conference on Computing, Networking and Communications (ICNC). Big Island, 2020: 304—308.
- [7] QIN X T, SONG Z Y, HAO Y Y, et al. Joint resource allocation and trajectory optimization for multi-UAV-assisted multi-access mobile edge computing[J]. *IEEE Wireless Communications Letters*, 2021, 10(7): 1400—1404.
- [8] ZHANG J, ZHOU L, ZHOU F H, et al. Computation-efficient offloading and trajectory scheduling for multi-UAV assisted mobile edge computing[J]. *IEEE Transactions on Vehicular Technology*, 2020, 69(2): 2114—2125.
- [9] WANG Y, RU Z Y, WANG K Z, et al. Joint deployment and task scheduling optimization for large-scale mobile users in multi-UAV-enabled mobile edge computing[J]. *IEEE Transactions on Cybernetics*, 2020, 50(9): 3984—3997.
- [10] HONG D, LEE S, CHO Y H, et al. Energy-efficient online path planning of multiple drones using reinforcement learning[J]. *IEEE Transactions on Vehicular Technology*, 2021, 70(10): 9725—9740.
- [11] WANG L, WANG K Z, PAN C H, et al. Multi-agent deep reinforcement learning-based trajectory planning for multi-UAV assisted mobile edge computing[J]. *IEEE Transactions on Cognitive Communications and Networking*, 2021, 7(1): 73—84.
- [12] ZHAO N, YE Z Y, PEI Y Y, et al. Multi-agent deep reinforcement learning for task offloading in UAV-assisted mobile edge computing[J]. *IEEE Transactions on Wireless Communications*, 2022, 21(9): 6949—6960.
- [13] LUO X J, XIE J, XIONG L Q, et al. 3-D deployment of multiple UAV-mounted mobile base stations for full coverage of IoT ground users with different QoS requirements[J]. *IEEE Communications Letters*, 2022, 26(12): 3009—3013.
- [14] DU Y, YANG K, WANG K Z, et al. Joint resources and workflow scheduling in UAV-enabled wirelessly-powered MEC for IoT systems[J]. *IEEE Transactions on Vehicular Technology*, 2019, 68(10): 10187—10200.
- [15] ZENG Y, ZHANG R. Energy-efficient UAV communication with trajectory optimization[J]. *IEEE Transactions on Wireless Communications*, 2017, 16(6): 3747—3760.
- [16] LYU X C, TIAN H, NI W, et al. Energy-efficient admission of delay-sensitive tasks for mobile edge computing[J]. *IEEE Transactions on Communications*, 2018, 66(6): 2603—2616.
- [17] DAI C, ZHU K, HOSSAIN E. Multi-agent deep reinforcement learning for full-duplex multi-UAV networks[C]//2022 IEEE Wireless Communications and Networking Conference (WCNC). Austin, 2022: 2232—2237.
- [18] DING R J, XU Y D, GAO F F, et al. Trajectory design and access control for air-ground coordinated communications system with multiagent deep reinforcement learning[J]. *IEEE Internet of Things Journal*, 2022, 9(8): 5785—5798.
- [19] 方维维, 王云鹏, 张昊, 等. 基于多智能体深度强化学习的车联网通信资源分配优化[J]. *北京交通大学学报*, 2022, 46(2): 64—72.

FANG Weiwei, WANG Yunpeng, ZHANG Hao, et al. Optimized communication resource allocation in vehicular networks based on multi-agent deep reinforcement learning[J]. *Journal of Beijing Jiaotong University*, 2022, 46(2): 64—72.(in Chinese)